

聚合物图表示学习

两篇论文精读与对比

重复不变性 · 自监督预训练 · 小样本性质预测

中文研究笔记 | 2026年9月28日

论文 A | GRIN

Learning Repetition-Invariant Representations for Polymer Informatics

Yihan Zhu, Gang Liu, Eric Inae, Tengfei Luo, Meng Jiang

NeurIPS 2025; 本文方法与数据核对采用 arXiv:2505.10726v3 (2026-01-03) 。 [1]

论文 B | 聚合物自监督 GNN

Self-supervised graph neural networks for polymer property prediction

Qinghe Gao, Tammo Dukker, Artur M. Schweidtmann, Jana M. Weber

Molecular Systems Design & Engineering, 2024, 9, 1130-1143.

DOI: 10.1039/D4ME00088A。 [2]

先抓住两篇论文的区别

问题	GRIN	自监督 GNN
最想解决什么	同一材料换一种重复次数表示，预测不应漂移。	性质标签很少，先用结构信息学习有用特征。
主要手段	重复单元增强 + max 消息聚合 + 稀疏约束。	节点/边掩码预训练 + 图级伪任务 + 有标签微调。
贡献所在	聚合物表示的稳定性与图尺寸外推。	多层次预训练与权重迁移的样本效率。

阅读提示：文中 [1]、[2] 对应末页参考文献。论文事实、方法解释与本文提出的研究建议分别表述；两篇论文的数据不用于直接排名。

01 | GRIN: 核心思想与方法

1. 为什么只输入一个重复单元不够？

同一种聚合物可以用一个重复单元 A，也可以用 A-A-A 等较长片段表示。单个单元可能缺少单元之间的连接环境；片段变长后，端部与内部原子的比例也发生变化。普通 GNN 的嵌入与性质预测因此可能随着表示长度改变。[1, § 1、§ 3]

GRIN 希望：在化学身份和目标标签保持不变时， $f(G_{\square})$ 、 $f(G_{\square\square})$ 、 $f(G_{\square\square\square})$ 尽可能一致。这里改变的是输入图中重复展开的次数，而不是为每条真实、不同分子量的链重新测量性质。

2. 数据层：重复单元增强 (RepAug)

利用聚合位点连接多个重复单元，构造 $G_{\square}$ 与 $G_{\square\square}$ ，并赋予相同性质标签。共聚物可以将一个固定组成的基元（例如 A-B 或 A-B-B）作为重复对象。默认训练集按 1:1 混合原始图与三重复图；模型不是只在三聚体上训练。[1, § 3.1、附录 B]

3. 模型层：max 消息聚合与残差更新

邻居节点与键的信息先经过消息网络 M，再逐维取最大值，最后由更新网络 U 与节点原状态组合。概念形式为：

新节点表示 = 旧节点表示 + U (旧节点表示, 逐维 max [邻居消息])

max 不会因为相同消息被重复加入而线性累加，提供了适合重复结构的归纳偏置。但不同特征维度可能选择不同邻居，不能简单理解为每个节点只保留一条完整化学键。

4. 稀疏约束与“最大生成树对齐”

训练损失由性质预测损失加上消息网络、更新网络参数的 L1 惩罚组成。作者将 max 选择与稀疏传播解释为和 Prim 最大生成树算法相似的贪心更新，从而支持图尺寸泛化。[1, 式 1-3]

这里的 MST 指 maximum spanning tree（最大生成树）。这主要是算法启发与对齐解释，不应描述成“先精确求出分子的生成树，再仅在树上预测”。max 与 L1 本身也不自动保证任意 GNN 都严格执行 Prim 算法。

02 | GRIN：理论、证据与适用边界

为什么强调三个重复单元？

训练表示	将每个重复单元缩成一个节点后	能看到的环境
A	单个孤立节点	没有单元间连接
A-A	两个端部节点	单侧邻居
A-A-A	两个端部 + 一个内部节点	首次出现来自两侧的消息

作者在一维超链抽象、消息传递收缩性等假设下，论证三个重复单元是暴露双分支聚合的最小结构；继续加长的边际收益减弱。这是特定模型与理论假设下的结论，不是“任何聚合物只算三聚体就足够”的物理定律。[1, § 3.3]

实验如何验证？

四个均聚物任务：玻璃化转变温度 7,174 条、熔点 3,651 条、密度 1,694 条、氧气渗透率 595 条；共聚物 EA 与 IP 各 3,000 条。划分为训练/验证/测试 60%/10%/30%，先划分再分别增强。均聚物主要比较 1 与 60 次重复，共聚物主要比较 1 与 20 次重复。[1, 表 1、附录 A]

证据（GCN 设置）	普通 GCN	GRIN
Tg RMSE: Test1 → Test60 (°C)	38.7 → 47.2	36.3 → 36.5
Tg R ² : Test1 → Test60	0.878 → 0.818	0.893 → 0.892
12,764 个无标签聚合物 G ₁ 与 G ₂ 的嵌入余弦相似度	0.672 ± 0.119	0.999 ± 0.000

前两行取原文表 2 的均值；最后一行来自附录表 11，是表征稳定性测试，不是这批数据的性质预测精度。0.000 是表格舍入后的标准差。

最重要的边界

重复不变性适用于“同一材料的等价表示”。真实分子量、端基、分散度、结晶与加工历史会影响性能，不能通过强行不变而删除这些信息。论文也未证明随机、支化、交联聚合物都可由同一固定重复模式充分描述；其共聚物讨论主要覆盖固定基元的嵌段与交替形式。[1, 附录 E；本段含方法边界分析]

03 | 自监督 GNN：表示与预训练任务

1. 核心思想：先理解结构，再学习性质

获得大量可靠性质标签往往比获得结构更困难。作者先让网络完成由结构自动生成答案的伪任务，再用较少 EA/IP 标签微调。主要创新是围绕聚合物图系统比较自监督任务和迁移方式；随机图表示与 wD-MPNN 骨干来自 Aldeghi 等前期工作，并非该文从头提出。[2, § 2]

2. 聚合物如何表示？

使用带权、有向的随机聚合物图：原子为节点、键为有向边；节点权重表达所属单体的组成比例，单体间边权表达连接概率，单体内部边权为 1。因此输入可以区分单体化学结构、计量比以及随机/交替/嵌段等架构，而不必显式展开一条极长链。[2, § 2.1]

wD-MPNN 先在有向边上传递消息，并按连接概率加权；随后汇聚成原子表示，再按组成权重得到聚合物向量，由全连接网络预测目标。它编码的是结构分布的统计信息，并不重建每条真实链的完整序列或三维构象。

3. 节点与边级预训练 (NE)

每个图随机选择两个节点特征向量和两个边特征向量，将其置零。模型根据剩余邻域信息重建被遮住的特征。该任务在节点/边层面预测，不需要先做整图池化。它鼓励网络学习局部化学环境，例如原子类型、键类型及其关联。[2, § 2.3.1]

4. 图级预训练 (G)

由单体质量和组成比例计算伪标签： $M_{ensemble} = w_A \times MA + w_B \times MB$ 。模型经 sum pooling 得到图表示，再回归这个伪标签。这使网络学习结构与组成的整体汇总。[2, § 2.3.2]

特别注意：这个伪标签是按比例加权的单体分子量，不是实验测得的整条聚合物 M_n 或 M_w ，也不是链长分布。它可以从结构直接计算，所以无需额外实验标签。

5. 联合方案 (NEG) 实际怎么训练？

先做节点/边掩码预训练，再迁移同一个编码器做图级伪标签预训练，最后进行 EA 或 IP 有监督微调。它是连续的三阶段训练，不是两个独立模型训练后平均权重，也不是原文明确采用的多损失同时联合训练。[2, § 2.3.3]

04 | 自监督 GNN：数据、迁移与结果

数据与训练流程

原文使用 42,966 个共聚物记录，正文 § 2.4 写明由 9 种 A 单体和 862 种 B 单体组成，包含三类链架构和 1:1、1:3、3:1 三种计量比；标签为计算得到的 EA 和 IP。该集合不是 42,966 个互不相关的单体，也不是电池粘结剂实测数据库。[2]

随机打乱后，40% 用于自监督预训练；最多另 40% 用于有标签微调；剩余 20% 用于测试。微调数据从总数据的 0.08% 增加至 40%，即约 34 条至 17,186 条（按比例估算，非声称原文精确取整值）。预训练阶段只使用结构派生标签，不使用 EA/IP。

迁移策略	从预训练保留什么	微调含义
a	消息传递层	读出全连接层重新初始化
b	消息传递层 + 两个全连接层	部分读出知识继续沿用
c	消息传递层 + 全部全连接层	尽可能保留预训练参数，再针对目标更新

论文设置：3 层边中心消息传递，隐藏维度 300，3 层全连接层；Adam，学习率 0.001，batch size 64，训练 100 epochs；结果曲线汇总 10 次运行。迁移是初始化后微调，不等于冻结所有层。[2，§ 2.3.4、§ 2.5、图 7]

最小标签规模下的代表结果

0.08% 标签；RMSE (eV)	EA	IP
从头监督训练	0.479	0.372
仅节点/边预训练 (NE)	0.424	0.317
顺序预训练 NEG，仅迁移消息层	0.433	0.340
顺序预训练 NEG，全部层迁移	0.343	0.301
相对从头训练的 RMSE 降幅	28.39%	19.09%

数值来自原文表 4、表 6。降幅 = (基线 RMSE - 新 RMSE) / 基线 RMSE。不能将摘要降幅误归因于“只做掩码预训练”。

主要启示：预训练任务与迁移范围都重要。图级任务单独使用并不总能提升 EA/IP；标签变多后优势缩小。全文的最佳整体趋势，也不意味着 NEG 在每个数据规模、每个目标上都绝对最优。

05 | 两篇论文的系统对比

维度	GRIN [1]	自监督 GNN [2]
研究瓶颈	表示随重复展开次数变化；尺寸泛化不足。	性质标签稀缺；从头训练不充分。
聚合物图	显式连接重复基元的原子图。	带组成权重与连接概率的随机图。
主要归纳偏置	同一材料的不同重复表示应一致。	局部化学结构与整体组成可迁移。
模型机制	max 消息聚合、残差更新、L1 稀疏惩罚。	wD-MPNN 的概率加权有向边消息传递。
训练信号	性质标签监督，G _{ext} /G _{int} 共享目标。	先结构伪标签，再 EA/IP 标签。
是否主要为 SSL	否；核心实验是带增强的监督预测。	是；比较 NE、G、顺序 NEG。
核心实验	六个性质任务，重复次数外推和嵌入稳定性。	EA/IP 两任务，标签规模与层迁移对比。
共聚物处理	固定可重复基元；随机架构仍待扩展。	直接以连接概率描述多类链架构。
理论/实证重心	超链抽象与算法对齐解释，加消融实验。	任务设计与迁移策略的系统实证。
未解决的因素	真实分子量效应、复杂拓扑、三维形貌。	真实链长分布、三维形貌、实验域迁移。
最值得借鉴	对等价结构表示做稳定性检验。	标签少时分阶段预训练，并检查负迁移。

不能直接比较谁“精度更高”

虽然都涉及 EA/IP，但 GRIN 的两个任务各 3,000 条，第二篇使用 42,966 条并专门改变微调规模；划分比例、架构与评估目的也不同。GRIN 检验的是表示尺寸外推，第二篇主要检验随机划分下的小样本学习，二者都不等同于对全新单体化学空间的严格外推。

公平比较需要统一数据、标签处理、训练/验证/测试划分、随机种子及计算预算，并同时报告性质误差、不同重复表示的预测偏差，以及新单体分组测试结果。此处为本文的比较分析。

06 | 如何用于新的聚合物性质研究？

以下为根据两篇论文提出的研究建议，不是原文已经验证过的组合模型。

1. 先区分应该保持不变与必须保留的信息

重复展开次数是输入表示的自由度，适合做一致性约束；共聚比例、真实分子量、分散度、端基和加工条件是材料变量，应作为输入保留。对于电解质或粘结剂，盐种/盐浓度、溶剂、温度及界面对象也应进入建模。

2. 可以组合，但不能机械拼接

可先借鉴 NE 掩码任务预训练聚合物编码器，再针对等价重复图引入一致性学习或重复增强，最后进行性质微调。如果主干仍使用概率加权求和，则不能声称自动继承 GRIN 的理论保证；若全部换成 max，也要检验是否损失组成与连接概率信息。

图级伪任务应服务于目标。针对溶解性或界面作用，可以探索结构可计算的极性/官能团统计等任务；这些是候选设计，需要消融验证。若采用 DFT 结果作为标签，则属于计算性质预训练，不能与完全不需要性质标签的结构自监督混为一谈。

3. 最小而有解释力的消融组合

模型	希望回答的问题
相同骨干，从头监督训练	可靠基线是多少？
基线 + NE 自监督	局部结构预训练是否有益？
基线 + 重复单元增强	不改变模型，仅增强能改善多少？
GRIN 风格主干 + 增强	结构归纳偏置是否额外有效？
预训练 + 不变表示学习 + 微调	两条路线是否互补，还是出现负迁移？

4. 同时评估三类泛化

性质准确性：报告 MAE/RMSE、 R^2 和多次运行波动。表示稳定性：固定材料身份，比较 $G_{\square}$ 、 $G_{\square}$ 、 $G_{\square\square}$ 、 $G_{\square\square}$ 的嵌入及预测偏差。化学外推：按单体、骨架或材料家族分组测试，避免高度相似共聚物同时进入训练和测试。

增强必须在数据划分后实施，同一材料的所有重复表示放在同一分组。真实分子量不同的样品不能仅因重复单元相同就强制共享标签。对于几十个实验样本，需控制模型容量，并与描述符 + 简单回归等基线比较。

07 | 关键问题速答与参考来源

Q1: GRIN 是主动学习、生成模型或大规模预训练模型吗？

这篇论文的核心都不是这些。它是一种聚合物图表示与监督性质预测方法，重点是重复增强、算法对齐及图尺寸泛化。

Q2: 第二篇的 NE 和 G 是训练完再融合权重吗？

不是。NEG 是 NE 预训练 → 将编码器迁移到 G 预训练 → 性质微调。同一编码器参数持续更新；“ensemble”在这里不应被读成通常意义的多个独立模型预测平均。

Q3: 两个模型是否解决了“单体 SMILES 就能预测所有聚合物性质”？

没有。它们改进了结构表示和训练效率，但没有替代分子量、组成、链序列、形貌及实验条件等必要信息。对溶解性、粘结强度、离子电导率等任务，应逐一判断缺失变量。

Q4: 数据是否可追溯？

第二篇在 Data availability 中明确指向公开的 polymer-chemprop-data 数据库。GRIN 附录说明了均聚物数据来源、EA/IP 数据来源与样本量；本笔记未核验其全部训练代码、处理后数据和复现实验，因此不声称已经完整复现。

参考文献与阅读定位

[1] Zhu, Y.; Liu, G.; Inae, E.; Luo, T.; Jiang, M. Learning Repetition-Invariant Representations for Polymer Informatics. NeurIPS 2025. 本文核对版本：arXiv:2505.10726v3, 2026-01-03。

<https://arxiv.org/abs/2505.10726>

重点：§ 3 方法与理论；表 1-4 性质结果；附录 A/B 数据与训练；表 11 表征稳定性；附录 E 局限。

[2] Gao, Q.; Dukker, T.; Schweidtmann, A. M.; Weber, J. M. Self-supervised graph neural networks for polymer property prediction. Mol. Syst. Des. Eng. 2024, 9, 1130-1143. DOI: 10.1039/D4ME00088A.

<https://doi.org/10.1039/D4ME00088A>

重点：§ 2.1/2.2 聚合物图与骨干；§ 2.3.3 顺序预训练；§ 2.3.4 层迁移；§ 2.5 数据划分；表 4、6 结果。

公开数据入口（由论文 [2] 指明）：

<https://github.com/coleygroup/polymer-chemprop-data>

版本说明：GRIN 使用比会议年份更新的作者修订稿，复现时应固定论文与代码版本。第二篇表 6 图注对“without transferring”的表述与正文策略描述存在不一致，本笔记按 § 2.3.4、图 9 和正文解释策略 a/b/c。